



Ministério da Educação  
Secretaria de Educação Profissional e Tecnológica  
Instituto Federal Catarinense  
*Campus Rio do Sul*

---

**MATHIAS ARTUR SCHULZ**

**DETECÇÃO DE *FAKE NEWS* A PARTIR DE  
REDES NEURAIS ARTIFICIAIS**

Rio do Sul

2020

## SUMÁRIO

1 INTRODUÇÃO.....	4
1.1 PROBLEMATIZAÇÃO.....	5
1.1.1 Solução Proposta.....	6
1.1.2 Delimitação do Escopo.....	7
1.1.3 Justificativa.....	7
1.2 OBJETIVOS.....	8
1.2.1 Objetivo geral.....	8
1.2.1 Objetivos específicos.....	8
1.3 METODOLOGIA.....	9
1.4 CRONOGRAMA.....	9
2 FUNDAMENTAÇÃO TEÓRICA.....	11
2.1 FAKE NEWS.....	11
2.1.1 Impactos das Fake News.....	12
2.1.2 Formas de combate utilizadas para as fake news.....	13
2.1.3 Checagem de fatos.....	14
2.2 REDES NEURAIIS ARTIFICIAIS.....	16
2.2.1 Neurônio biológico.....	17
2.2.2 Neurônio Artificial.....	19
2.3 RNA'S UTILIZADAS.....	21
2.3.1 Multilayer Perceptron.....	21
2.3.2 Redes Neurais Recorrentes.....	23
2.3.2.1 Long Short-Term Memory.....	23
3 TRABALHOS CORRELATOS.....	25



## 1 INTRODUÇÃO

As falsas notícias, também chamadas de *fake news*, não são novas no cotidiano das pessoas, entretanto a internet alavancou o seu crescimento e facilitou a forma como elas são disseminadas. São fabricadas e construídas com base em notícias atuais, entretanto possuem diferenças quanto a suas intenções (BAUM *et al.*, 2018), no qual possuem como principal objetivo enganar seus leitores a partir de notícias que são falsas intencionalmente (LIM; LING; TANDOC JR, 2017).

Segundo o dicionário de Cambridge *fake news* são falsas histórias que parecem ser notícias, se encontram espalhadas na internet ou usando outras mídias, geralmente criadas para influenciar opiniões políticas ou utilizadas como uma piada (FAKE NEWS, 2020). Se tornam populares principalmente devido a sua inserção em diversas áreas e tópicos, como: política, doenças, vacinas, nutrição e valores das ações (BAUM *et al.*, 2018).

A criação de *fake news* são motivadas a partir de dois fatores principais, que são: O financeiro, a partir do desenvolvimento de histórias falsas e que instigam as pessoas à leitura, propagam rapidamente a notícia e geram lucros ao autor a partir dos cliques na notícia; E ideológico, promovendo ou desfavorecendo pessoas específicas por meio da criação de falsas notícias (LIM; LING; TANDOC JR, 2017).

A internet e as mídias sociais são os principais canais para a disseminação de notícias falsas, principalmente a partir da facilidade da criação de novos sites. Além disso, não apenas fornecem um meio para publicar essas histórias, mas também oferecem ferramentas para promover ativamente a sua divulgação (BAUM *et al.*, 2018).

Para o combate de *fake news*, é possível realizar uma separação em duas categorias: A primeira forma está relacionada ao aumento da capacidade dos indivíduos em avaliar as notícias, buscando características que levem ao levantamento de um relato falso. Por exemplo, a partir de sites que avaliam a veracidade das informações, como o *PolitiFact* e *Snopes*; E a segunda categoria é a busca por mudanças estruturais que diminuam o acesso dos indivíduos às falsas resenhas (BAUM *et al.*, 2018).

Segundo uma pesquisa realizada pelo site de notícias e entretenimento *BuzzFeed* em 2016, *fake news* de jornais enganam os adultos americanos cerca de 75% das vezes. (LIM; LING; TANDOC JR, 2017). Os indivíduos tendem a aceitar as notícias com maior facilidade a partir de informações que se alinhem com suas respectivas crenças (como partidárias e ideológicas) e também por meio de notícias que agradem aos indivíduos (BAUM *et al.*, 2018).

Um grande desafio para os indivíduos é a identificação, compreensão e a distinção a partir do olho humano entre notícias reais e falsas (DAWN; MITTAL; VERMA, 2019). Com isso, Redes Neurais Artificiais (RNA) podem ser utilizadas para a detecção de *fake news*, a partir de diversos modelos existentes. A detecção de *fake news* também é um obstáculo para os métodos de análise utilizados atualmente, como métodos de aprendizado tradicional e modelos de aprendizado profundo. Entretanto, grande parte dos modelos atuais não são capazes de identificar notícias recentes eventos críticos em termos de tempo (ADBULLAH; QAWASMEH; TAWALBEH, 2019).

Considerando os recentes avanços das RNAs, o propósito principal deste trabalho é desenvolver um modelo de detecção de falsas notícias (*fake news*) em sites de notícias disponíveis nas mídias sociais por meio da técnica de Redes Neurais Artificiais, utilizando a abordagem de aprendizado profundo (*Deep Learning*). A pesquisa realiza também um comparativo entre dois modelos, uma utilizando o aprendizado profundo e outra não utilizando. Essa comparação visa constatar ou não, a vantagem do aprendizado profundo sobre a abordagem tradicional na identificação de *fake news*.

## 1.1 PROBLEMATIZAÇÃO

A detecção manual de uma *fake news* pode ser realizada de algumas formas, por exemplo buscando outras fontes e sites, modificando o algoritmo de busca *PageRank* da Google, possibilitando a busca a partir da importância e confiança das referências e não apenas a partir da quantidade de referências utilizadas. Entretanto, também é possível utilizar informações das notícias para sua classificação, como fontes, títulos, texto, imagens. Dessa forma, as RNAs permitem a detecção de falsas notícias a partir da diferença na estrutura do texto (MARUNO, 2018).

Existem diversos desafios para detectar *fake news*, em grande parte dos casos, elas se baseiam em histórias verdadeiras com poucos detalhes falsos, dificultando seu reconhecimento e enganando os leitores. As *fake news* possuem uma grande complexidade e podem ser separadas em três tipos de notícias, que são: sátira, fraude e propaganda, no qual a formação dessas falsas histórias ocorrem por meio de palavras subjetivas, intensificadas e de cobertura, com a intenção de introduzir uma linguagem vaga, obscurecedora, dramatizante ou sensacionalista (TIM, 2018).

A classificação de uma notícia é trabalhosa e complexa, além de necessitar

bastante tempo do especialista. Com isso, para a resolução desse problema é possível a utilização Aprendizado de Máquina que realiza a classificação de forma mais rápida e, em alguns casos, mais precisa que os seres humanos. Contudo, a classificação de texto é complexa e abstrata, por isso o *Deep Learning* (subárea do aprendizado de máquina) pode ser um grande facilitador para esse problema (MARUNO, 2018).

A aplicação de abordagens para detecção de falsas notícias é trabalhosa, principalmente devido à complexidade das notícias, além disso outro fator determinante é a busca e criação de um conjunto de dados que possua notícias reais e falsas disponíveis na língua portuguesa, devido ao fato de grande parte dos estudos já realizados nessa área utilizarem como base a língua inglesa.

De acordo com estudos já realizados pelos autores citados acima, a detecção de *fake news* pode ser realizada a partir de diversas abordagens, como o aprendizado profundo. No entanto, grande parte dos autores focam na língua inglesa como base para a detecção, dessa forma surge a seguinte pergunta de pesquisa: É possível obter um resultado favorável na detecção de *fake news* utilizando como base a língua portuguesa?

### 1.1.1 Solução Proposta

A proposta deste trabalho é desenvolver um modelo de detecção de *fake news* baseado em Redes Neurais Artificiais para as áreas de interesse utilizando como conjunto de dados notícias reais e falsas. Neste problema, serão comparados dois modelos de RNAs, um que utiliza a abordagem de aprendizado profundo e outro que não a utiliza. Além disso, a adequação de uma topologia de RNA a um problema particular de detecção inclui diversos complicadores, dentre os quais:

1. Obtenção de notícias reais e falsas na língua portuguesa;
2. Tratamento dos dados;
3. Conversão dos dados para representação numérica;
4. Definição das variáveis de entrada;
5. Algoritmo de treinamento;
6. Algoritmo de otimização;
7. Função de ativação;
8. Número de camadas intermediárias;
9. Número de neurônios nas camadas intermediárias da rede.

### 1.1.2 Delimitação do Escopo

O estudo apresentará a modelagem de duas Redes Neurais Artificiais para a detecção de *fake news*. Será considerado a Rede Neural Recorrente LSTM (*Long Short Term Memory*) utilizando a abordagem de aprendizado profundo e a Rede Neural Artificial MLP (*Multilayer perceptron*) utilizando a abordagem tradicional. Além disso, a aplicação estará restrita à área de estudo selecionada, que consiste em notícias escritas na língua portuguesa.

### 1.1.3 Justificativa

O grande número de indivíduos divulgando notícias teve um grande crescimento nos últimos anos, principalmente nas mídias sociais. Esse aumento levou a um grande número de notícias difíceis de serem classificadas como verdadeiras ou falsas (ADBULLAH; QAWASMEH; TAWALBEH, 2019). Além disso, segundo Jacob, diretor administrativo do site de verificação de fatos BOOM, de Mumbai, o ano de 2019 foi o ano mais movimentado para verificadores de fatos até agora, atingindo o maior pico de falsas notícias criadas (CHATURVEDI, 2019).

Segundo Chaturvedi (2019) a disseminação de *fake news* não apresenta sinais de declínio, mesmo com algumas medidas realizadas pelos governos e plataformas das mídias sociais. A entidade sem fins lucrativos *Check4Spam*, responsável por verificar a veracidade das notícias nas mídias sociais, relata que no ano de 2019 o número de mensagens recebidas para verificação teve um aumento de mais de 20%, subindo de 4.000 mensagens no ano de 2018 para aproximadamente 5.000 a 6.000 postagens por mês no ano de 2019, sendo um dos principais impulsionadores os eventos que ocorrem durante o ano.

Para a detecção de *fake news*, redes neurais genéricas também podem ser utilizadas, assim como são empregadas para diversas outras aplicações, como visão computacional e reconhecimento de fala. Contudo, elas não oferecerão um excelente desempenho e não funcionarão muito bem para grandes aplicações, com isso é necessário o uso de estratégias específicas. O *Deep Learning* permite o uso de técnicas especializadas para a modelagem de linguagem natural e processamento de dados sequenciais (BENGIO; GOODFELLOW; COURVILLE, 2015).

Segundo Deng e Yu (2013) o *Deep Learning* é uma classe de técnicas do

aprendizado de máquina, no qual apresentam muitas camadas intermediárias para o processamento de informações não lineares, extração e transformação de recursos supervisionados ou não supervisionados e análise e classificação de padrões.

A carência por formas de detecção de *fake news* na língua portuguesa, viabilizou a elaboração da investigação no tema. O presente trabalho auxiliará a comunidade online na detecção de falsas notícias, prevenindo a disseminação de notícias criadas apenas com a intenção espalhar falsas histórias.

Levando em consideração as afirmações dos autores citados, pretende-se através do presente trabalho contribuir para a literatura por meio da modelagem de um modelo de RNA para detecção de *fake news* e de um comparativo de tal modelo em vários níveis de profundidade.

## 1.2 OBJETIVOS

Esta seção descreve os objetivos geral e específicos do trabalho.

### 1.2.1 Objetivo geral

Desenvolver um modelo de detecção de falsas notícias em sites de notícias brasileiros disponíveis nas mídias sociais por meio da técnica de Redes Neurais Artificiais.

### 1.2.1 Objetivos específicos

Os objetivos específicos deste trabalho estão descritos a abaixo.

1. Investigar quais modelos têm sido utilizados no problema da detecção de falsas notícias;
2. Definir as principais variáveis que possam auxiliar na detecção de falsas notícias;
3. Obter conjuntos de dados para treinamento, testes e validação dos modelos;
4. Modelar e treinar os modelos em diversas configurações para detecção de falsas notícias no local de estudo selecionado;
5. Comparar as detecções realizadas pelos modelos com os dados de validação;



### 1.3 METODOLOGIA

Esta seção apresenta a metodologia empregada para o desenvolvimento do trabalho.

1. Revisão bibliográfica: Esta etapa objetiva o aprofundamento teórico acerca de detecção de *fake news* e Redes Neurais Artificiais aplicadas a este problema. A pesquisa bibliográfica foi realizada em livros, teses, dissertações, monografias e artigos de periódicos;
2. Revisão sistemática da literatura: Esta etapa identificou o estado da arte na área de detecção de *fake news*. Delimitou quais modelos e métodos têm sido aplicados e identificou as características das detecções, como métricas de erro e variáveis de entrada utilizadas;
3. Tratamento dos dados: Com os dados obtidos realizou-se a normalização dos dados através de técnicas de Processamento de Linguagem Natural;
4. Modelagem das Redes Neurais Artificiais: Nesta etapa, são modeladas e treinadas diferentes configurações de RNAs para realizar a detecção das *fake news* nas áreas de interesse.
5. Comparação das RNAs: Obtenção do menor erro de cada modelo utilizado. Com isso, avaliação e comparação do desempenho das RNAs a partir das métricas de erro. As detecções realizadas por estas redes são comparadas com os dados reais sobre *fake news*.

### 1.4 CRONOGRAMA

Esta seção apresenta a tabela do cronograma de etapas realizados na construção deste trabalho.

Tabela 1: Cronograma de atividades

<b>Etapas</b>	<b>Mar</b>	<b>Abr</b>	<b>Mai</b>	<b>Jun</b>	<b>Jul</b>	<b>Ago</b>	<b>Set</b>	<b>Out</b>	<b>Nov</b>
Pesquisa do tema	X								
Revisão Bibliográfica	X	X							
Determinação dos objetivos		X							
Localização e identificação das fontes para obtenção do <i>dataset</i>	X	X							
Obtenção do <i>dataset</i> sobre <i>fake news</i>			X						
Ajustes e análise no <i>dataset</i>				X					
Representação numérica do <i>dataset</i>				X	X				
Desenvolvimento					X	X	X		
Realização de testes							X	X	
Validação dos resultados								X	
Entrega e defesa do trabalho									X

Fonte – Acervo do Autor

## 2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, são abordados conceitos relacionados às áreas de Redes Neurais Artificiais (RNAs) e *fake news*, os quais são fundamentais para a realização e clareza deste trabalho.

### 2.1 FAKE NEWS

No século XX, as propagandas em massa foram para os nazistas uma ótima forma de disseminar falsas notícias a seu favor e obter a atenção dos alemães. Antes do amplo uso da internet e as mídias sociais, divulgar uma *fake news* era mais complexo, pois prejudicava a reputação da publicação, possuía um alto custo de distribuição e o autor era penalizado (TRAUMANN, 2017).

No entanto, Traumann (2017) relata que atualmente os custos de divulgação de falsas notícias por meio das mídias sociais são pequenos e/ou inexistentes, a probabilidade do autor ser descoberto é menor e, além disso, indivíduos que produzem esses tipos de notícias não estão preocupados com sua reputação.

O conceito de notícias falsas surgiu como uma expressão para artigos que são falsos de forma intencional e verificada, parecem autênticos, no entanto possuem falsos fatos com o objetivo de atrair e enganar os leitores. Além disso, *fake news* são fabricadas imitando a forma do conteúdo de uma notícia, mas não conseguem copiar o processo e o propósito organizacional (RIBEIRO; ORTELLADO, 2018).

De acordo com Ribeiro e Ortellado (2018), as *fake news* são provenientes a partir de diversas formas de comunicação, dentre os quais pode ser: Artigos de notícias, opiniões, paródias e sarcasmo, assim como rumores, memes, boatos, entre outros. Entretanto, é importante observar alguns casos que não são considerados falsas notícias, por exemplo:

- ➔ Erros não intencionais em reportagens;
- ➔ Rumores não provenientes de um artigo de notícia;
- ➔ Teorias da conspiração;
- ➔ Falsas afirmações de políticos.

Para uma tentativa de combate às *fake news* no Brasil, o Supremo Tribunal Federal (STF) lançou, em Junho de 2019, o Painel Multissetorial de Checagem de Informações e Combate a *Fake News*, no qual reuniu jornais, agências, associações de juízes e

tribunais superiores para a criação de sites e projetos com o objetivo de investigar e analisar as informações que circulam nas mídias sociais (BARBOSA; SANTI, 2019).

De acordo com uma pesquisa realizada pelo instituto Ipsos, 62% dos brasileiros acreditam em notícias que na verdade eram falsas notícias. Com isso, é possível analisar que poucas pessoas buscam saber mais sobre as notícias lidas e verificar se a fonte e as informações da notícia são realmente verdadeiras (BARBOSA; SANTI, 2019).

Segundo Barbosa e Santi (2019), as notícias falsas compartilhadas garantem poder e vantagem, em muito casos o conteúdo causa julgamento precipitado e preconceitos, violência verbal e discriminação. Desta forma, podem ser utilizadas como aparato político e de poder para disseminar ideologias, favorecer determinadas pessoas e denegrir a imagem de outras, como políticos e outros agentes.

Para determinados indivíduos nas redes sociais, notícias que se alinhem a sua visão e ponto de vista, fazendo com que atinja as expectativas, pensamentos e preconceitos, independente da veracidade já é vista como uma notícia verdadeira. Com isso, a notícia passa a ser vista do ângulo subjetivo e emocional, que leva a aprovação de falsas informações e a manipulação do leitor a mudar seu pensamento sobre determinados temas, como na área política e científica (BARBOSA; SANTI, 2019).

### **2.1.1 Impactos das Fake News**

Delmazo e Valente (2018) relatam uma pesquisa realizada pelo site *Buzzfeed News*, no qual apresentou que nos três últimos meses da campanha para as eleições presidenciais dos Estados Unidos, no ano de 2016, as principais as notícias falsas do Facebook eram mais populares e aceitas do que as principais notícias de veículos de comunicação, como o *The New York Times*, *Washington Post*, *Huffington Post*, *NBC News*, entre outros.

Além disso, as 20 notícias falsas com melhor performance na rede social possuíram 8.711.000 compartilhamentos, comentários e reações (DELMAZO; VALENTE, 2018). Dentre as principais notícias falsas que repercutiram, destacam-se por exemplo: “Wikileaks confirma que Clinton vendeu armas para o Estado Islâmico” e “Papa Francisco choca o mundo e apoia Donald Trump” (SPINELLI; SANTOS, 2018).

De acordo com Spinelli e Santos (2028), um caso de destaque ocorreu em uma pizzeria da Carolina do Norte, no qual um homem de 28 anos entrou atirando com o objetivo

de investigar por conta própria uma teoria da conspiração fictícia que se propagou rapidamente durante as eleições, no qual a pizzeria estava mantendo um cativado de tráfico sexual de crianças com o auxílio financeiro do Partido Democrata, felizmente nenhuma pessoa se feriu.

No Brasil, de acordo com uma pesquisa realizada pelo Grupo de Pesquisa em Políticas Públicas de Acesso a Informação da Universidade de São Paulo (USP), durante a semana anterior a votação de abertura do processo de Impeachment da então presidenta Dilma Rousseff, as cinco notícias mais compartilhadas no Facebook, três dessas eram falsas (DELMAZO; VALENTE, 2018).

Segundo Delmazo e Valente (2018), quando uma notícia é acessada, um dos grandes impactos está relacionado a qualidade da leitura, é necessário prestar uma atenção especial ao que está sendo lido, para que os artigos não fiquem descontextualizados em relação às suas fontes e que os fatos não se misturem livremente com ficção.

Um boato disseminado nas redes sociais do Brasil, relatava que a ex-primeira dama Marisa Letícia, morta em 3 de fevereiro de 2017, estaria viva e viajando pela Itália. Além disso, outra *fake news* afirmava que o viúvo Marisa Letícia, o ex-presidente Luiz Inácio Lula da Silva, teria solicitado pensão referente ao salário de Marisa como servidora do Congresso Nacional, no valor de R\$ 68 mil (DELMAZO; VALENTE, 2018).

Spinelli e Santos (2028) destacam uma pesquisa do *Pew Research Center*, no qual as notícias falsas confundem a interpretação dos fatos e eventos atuais para 64% dos americanos entrevistados. Diversas *fake news* são disseminadas nas mídias sociais, os exemplos acima são uma pequena amostra dessas notícias e os riscos reais que elas representam para a sociedade contemporânea.

### **2.1.2 Formas de combate utilizadas para as fake news**

Sites responsáveis por disseminar notícias falsas estão a todo vapor na produção, devido principalmente aos cliques da audiência, que geram lucros, e a divulgação de *fake news* acaba sendo incentivada pela publicidade (SPINELLI; SANTOS, 2018).

Delmazo e Valente (2018) relatam que com o grande impacto das *fake news*, o Facebook a partir ano de 2016 iniciou o desenvolvimento de barreiras para a disseminação dessas notícias, como: Fim do patrocínio de publicações falsas; Possibilidade dos usuários denunciarem falsas notícias; Parceiras com verificadores de fatos; Alteração da linha do

tempo para reduzir a disseminação e o impacto das *fake news*; Maior dificuldade para criação de contas falsas.

No ano de 2017, o Facebook identificou e fechou 470 perfis russos que teriam gasto US\$ 100.000 em anúncios entre junho de 2015 e maio de 2017. Além disso, também foi lançado e disponibilizado uma ferramenta sobre dicas de como identificar notícias falsas (DELMAZO; VALENTE, 2018).

Segundo Delmazo e Valente (2018), uma das iniciativas realizada pelo Google, mídias tradicionais de diversos países e outras organizações foi a criação do *First Draft News*, com o objetivo de apresentar notícias adequadas aos usuários e combater as notícias falsas. Além disso, o *First Draft News* também realiza o monitoramento de eleições, como as que ocorreram nos Estados Unidos em 2016 e no Reino Unido, França e Alemanha em 2017.

Outra iniciativa realizada pelo Google foi a implementação de um selo de verificação nas páginas, junto com outras 115 organizações de verificação de fatos, a partir do selo é possível visualizar se a notícia é falsa a partir da checagem das organizações parceiras (DELMAZO; VALENTE, 2018).

A disseminação de *fake news* afeta a distinção do que é real na sociedade e o que é falso, ocasionando uma ameaça não apenas ao jornalismo, mas também à democracia. Deste modo, um desafio é que a própria audiência contraponha as falsas notícias, compreenda os métodos de apuração jornalística e que compartilhe e usufrua de veículos de comunicação que informam com credibilidade e precisão (DELMAZO; VALENTE, 2018).

### 2.1.3 Checagem de fatos

No jornalismo, a notícia é o principal produto, que é sustentado a partir da necessidade de percepção do seres humanos, o que acontece na cidade, no país, do outro lado do mundo. Além disso, o jornalismo possui um compromisso com a verdade, desta forma existe consentimento entre os jornalistas sobre a importância de apurar bem os fatos, com exatidão, equidade e verdade (DELMAZO; VALENTE, 2018).

De acordo com Delmazo e Valente (2018), a verificação dos fatos (*fact-checking*), desenvolvida de acordo com os procedimentos já especificados na reportagem jornalística, permite que a política não se afaste do que deveria ser, que não se afaste da sua relação com a verdade. O *fact-checking* possui preocupação com a transparência, credibilidade, busca pela diversidade de personalidades checadas e uma política clara de erros.

Nos Estados Unidos, com o lançamento do site *Factcheck.org*, o gênero *fact-checking* começou a conquistar reconhecimento e audiência. Além disso, teve seu ápice quando o projeto *PolitiFact* levou o prêmio *Pulitzer* em 2009 (DELMAZO; VALENTE, 2018).

Delmazo e Valente (2018) destacam que os responsáveis pela checagem de fato em todo mundo possuem uma norma internacional, o *International Fact-checking Network* – IFCN, possui um código de princípios, uma conferência global realizada todo ano e um dia internacional, o dia do *fact-checking* em 2 de abril, depois do da mentira (DELMAZO; VALENTE, 2018).

O IFCN, possui em abril de 2020, um total de 76 signatários verificados de acordo com código de princípios da IFCN, sendo duas agências do Brasil, Agência Lupa e Aos Fatos (IFCN, 2020). Todas as agências credenciadas devem estabelecer compromissos de apartidarismo, equidade, transparência das fontes, detalhes sobre métodos utilizados e correções francas e amplas (DELMAZO; VALENTE, 2018).

O IFCN possui 12 signatários verificados em renovação, que são avisados mês antes da data de vencimento com um período de três meses para concluir seu processo de renovação, estando sujeito a uma nova avaliação e aprovação pelo conselho consultivo da IFCN em referência ao código de princípios. Uma dos 12 signatários em renovação, sendo o único do Brasil, é a agência Estadão Verifica. Além disso, o IFCN possui 15 signatários expirados, sendo uma delas uma agência do Brasil, a Agência Público – Truco (IFCN, 2020).

Delmazo e Valente (2018) descrevem que a agência Lupa, é a primeira de *fact-checking* do Brasil, desde novembro de 2015. Possui como objetivo acompanhar o noticiário de política, economia, cidade, cultura, educação, saúde e relações internacionais, realizando correções e divulgando dados corretos quando necessário. Além disso, já produziu checagens em formatos de texto, áudio e vídeo (DELMAZO; VALENTE, 2018).

A agência Aos Fatos, possui bases no Rio de Janeiro e em São Paulo e é mantida por uma equipe de profissionais multidisciplinares e multitarefas. Possui como objetivo acompanhar declarações de políticos e autoridades de expressão nacional verificando se estão falando a verdade. Além disso, Aos Fatos é financiada por meio do seu programa de apoiadores, o Aos Fatos Mais, parcerias editoriais e projetos de tecnologia encubados no Aos Fatos Lab (AOS FATOS, 2020).

## 2.2 REDES NEURAIS ARTIFICIAIS

Uma Rede Neural Artificial (RNA) é um modelo que simula o comportamento e o funcionamento do cérebro humano (FINOCCHIO, 2014). É capaz de realizar problemas altamente complexos por meio de um processamento distribuído entre várias pequenas unidades interligadas, chamadas de neurônios (FURTADO, 2019). Porém, com uma quantidade de neurônio muito menor quando comparado ao cérebro humano (FINOCCHIO, 2014).

Segundo Furtado (2019), as conexões entre os neurônios possuem um determinado valor, denominado peso da conexão ou sinapse, no qual determinada o grau de conectividade entre os neurônios. Além disso, cada neurônio realiza um processamento de forma isolada e paralela aos outros, com isso o resultado é encaminhado aos próximos neurônios através das conexões.

A aptidão de uma RNA na resolução de um problema é determinado através da sua arquitetura, no qual é especificado a quantidade e forma de ligação dos neurônios, assim como o peso das conexões e o número de camadas (FURTADO, 2019).

Geralmente, a forma de resolução de um problema é baseado no método empírico, a partir dos processos de treinamentos e modificações graduais para adaptar e aperfeiçoar o modelo a solução do problema (FURTADO, 2019).

Furtado (2019) relata que as Redes Neurais Artificiais possuem três fases principais para resolução de um problema: Treinamento, no qual a partir de padrões de entrada o modelo treina, tenta resolver o problema e gera padrões de saída; Teste, os padrões de entrada são apresentados ao modelo e as saídas obtidas são comparadas às saídas desejadas; Aplicação, o modelo é utilizado para resolver determinado problema.

A primeira rede neural relatada em documentos datam o ano de 1943, escritos por McCulloch e Pitts. No qual propuseram um modelo de neurônio como uma unidade de processamento binária, sendo um modelo simples mas de grande importância para os próximos anos (FINOCCHIO, 2014).

No ano de 1949, Donald O. Hebb apresentou uma hipótese de como a força das sinapses no cérebro se modificam em resposta à experiência dos seres vivos. As conexões entre células que são ativadas ao mesmo tempo tendem a se fortalecer e as outras conexões tendem a se enfraquecer. Com isso, Donald O. Hebb foi o primeiro que propôs uma lei de aprendizagem para as sinapses dos neurônios e auxiliou como inspiração para outros pesquisadores (FINOCCHIO, 2014).



De acordo com Finocchio (2014), em 1957 surgiu o primeiro neuro computador que obteve sucesso, chamado Mark I Perceptron, desenvolvido por Frank Rosenblatt, Charles Wightman e outros pesquisadores. O neuro computador possuía como principal objetivo o reconhecimento de padrões. Entretanto, redes básicas como a perceptron, possuem algumas limitações básicas, apesar de serem capazes de executar as operações booleanas ‘e’ e ‘ou’ por exemplo, não são capazes de implementar outras regras lógicas simples, como o caso do ‘ou exclusivo’.

Finocchio (2014) descreve que nos anos seguintes houve uma queda de financiamentos para pesquisas sobre redes neurais, sendo um dos motivos devido a alta expectativa criada e baixos resultados obtidos. Entretanto, no ano de 1980, houve um crescimento do número de pesquisas realizadas e aplicações em sistemas reais, tudo isso devido a diversos fatores, dentro os principais podem ser citados:

- ➔ Neurofisiologistas com maior conhecimento sobre o processamento de informações nos organismos vivos;
- ➔ Novas tecnologias permitindo maior potencial computacional e baixo custo, o que possibilitou simulações e testes mais complexas;
- ➔ Novas teorias que serviram de base para o desenvolvimento de novos algoritmos.

Assim como o cérebro humano, as RNA's possuem capacidade de interagir com o meio externo e adaptar-se a ele. Esse motivo é o que permite que essas redes sejam utilizadas em diversas áreas de aplicação (FINOCCHIO, 2014), como engenharia, economia, agronomia, medicina. Resolvendo problemas como: Extração de características; Classificação; Categorização; Estimativa; Previsão; entre outros problemas (FURTADO, 2019).

### **2.2.1 Neurônio biológico**


O sistema nervoso é o responsável por coordenar as atividades dos vários tipos de tecidos e órgãos dos seres vivos, no qual cada um possui determinadas funções e responsabilidades. Como o tecido nervoso, no qual é constituído por dois componentes principais, que são os neurônios e as neuróglia (FURTADO, 2019).

De acordo com Furtado (2019), a neuróglia é composta por diversos tipos celulares que se apresentam entre os neurônios, sua função é a sustentação, nutrição e defesa nos neurônios. Além disso, também possui outras duas funções, uma na vida embrionária, no

qual estabelece sinapses adequadas para o crescimento dos dendritos e axônios. Na vida adulta, possibilita a formação de circuitos independentes que auxiliam os impulsos a serem espalhados corretamente.

Os neurônios são células que reagem a estímulos do meio no qual se encontram, por meio da alteração na diferença de potencial elétrico existente na superfície interna e externa da membrana celular. Por meio desses estímulos, a mudança de potencial é propagada a outros neurônios, músculos e glândulas (FURTADO, 2019). Os neurônios possuem, desta forma, um papel essencial no funcionamento, comportamento e raciocínio dos seres vivos (FINOCCHIO, 2014).

A figura abaixo apresenta a estrutura de um neurônio, que é composto por um corpo celular, onde se encontra o núcleo do neurônio. Do corpo celular partem os dendritos, responsáveis por receber estímulos. O axônio é um prologamento responsável por transmitir os impulsos com informações provenientes do corpo celular a outros neurônios, músculos e glândulas (FURTADO, 2019).



*Figura 1: Estrutura de um neurônio biológico (FURTADO, 2019)*

O envio e recebimento dos impulsos entre os neurônios dependem das sinapses, que são uma estrutura no qual ocorre o contato entre um axônio de um neurônio e um dendrito de outro neurônio, podendo ser excitatórias ou inibitórias (FURTADO, 2019).

De acordo com Finocchio (2014), o cérebro humano, uma das partes do sistema nervoso, é responsável pelo controle das funções e dos movimentos do organismo, no qual é composto por aproximadamente 100 bilhões de neurônios e cada neurônio se encontra

conectado a outros (aproximadamente 100 neurônios) através de sinapses, formando uma grande rede neural biológica, permitindo uma grande capacidade de processamento e armazenamento de informações.

### 2.2.2 Neurônio Artificial

Um neurônio artificial é uma estrutura lógico-matemática que tem por objetivo simular o comportamento e funcionamento de um neurônio biológico, realizando o processamento a partir de diversas entradas e fornecendo saídas (FURTADO, 2019).

Comparando um neurônio biológico com um artificial, como pode ser observado na figura abaixo, observa-se três elementos básicos, que são:

1. Entrada e Pesos: Os dendritos seriam os sinais de entradas (*Input signals*, representados por  $x_1, x_2, \dots, x_m$ ), no qual se comunicam com o corpo celular através de canais que possuem pesos sinápticos (*Synaptic weights*, representados por  $w_{k1}, w_{k2}, \dots, w_{km}$ ), neste caso os pesos são as sinapses do neurônio biológico (FURTADO, 2019). Cada entrada possui um peso ou força própria, um sinal  $x_m$  na entrada da sinapse  $m$  conectado ao neurônio  $k$  é multiplicado pelo peso sináptico  $w_{kj}$  (Neste caso, o  $k$  simboliza o neurônio em questão e  $m$  refere-se a sinapse à qual o peso se refere) (HAYKIN, 2009).
2. Função Soma: Após os estímulos serem captados, são processados a partir da função soma (*Summing junction*) (FURTADO, 2019). No qual, é realizado a soma dos sinais de entrada, ponderados pelas respectivas forças sinápticas do neurônio, representando uma combinação linear (HAYKIN, 2009).
3. Função de Ativação: Responsável por limitar a amplitude da saída de um neurônio, limita a faixa de amplitude permitida do sinal de saída para algum valor finito.

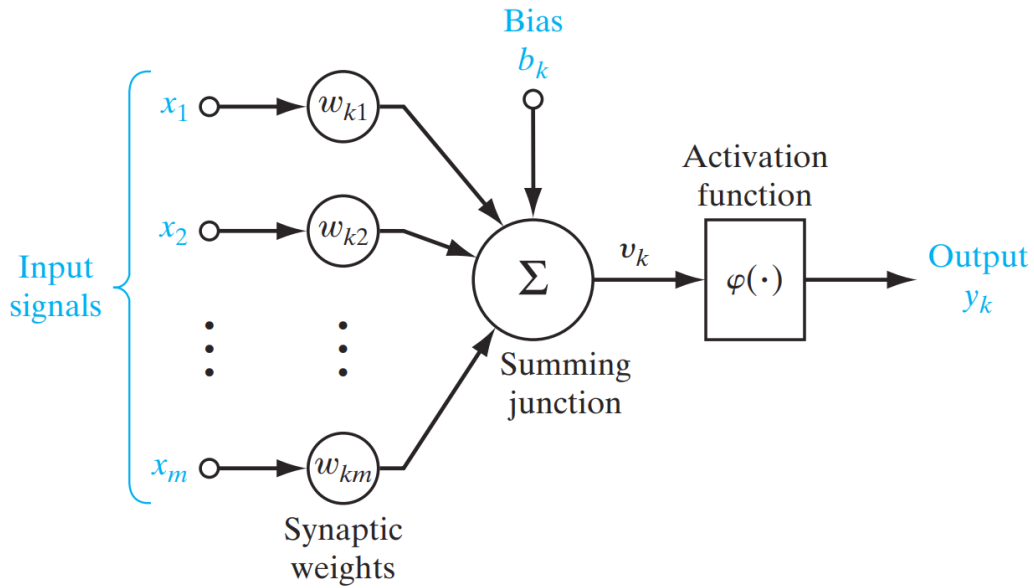


Figura 2: Estrutura de um neurônio artificial (HAYKIN, 2009)

De acordo com figura acima, observa-se também que a função soma possui um viés aplicado externamente, o limiar de ativação chamado de Bias, representado por  $b_k$ . Permite aumentar ou diminuir a entrada líquida da função de ativação, dependendo se é positivo ou negativo, respectivamente (HAYKIN, 2009).

Segundo Haykin (2009), o modelo da figura acima, na forma matemática pode ser representado da seguinte forma:

$$u_k = \sum_{j=1}^m w_{kj} x_j$$

$$y_k = \varphi(u_k + b_k)$$

No qual: Os valores de  $x_j$  são os sinais de entrada; os valores representados por  $w_{kj}$  são os pesos sinápticos;  $u_k$  é o resultado da combinação linear dos sinais de entrada e os pesos;  $b_k$  é o *bias*; A fórmula inferior representa a função de ativação; e  $y_k$  é o resultado do neurônio.

### 2.3 RNA'S UTILIZADAS

Neste capítulo é apresentado as Redes Neurais Artificiais utilizadas neste trabalho. Primeiramente é apresentado a RNA MLP e posteriormente é apresentado a rede

recorrente LSTM.

### 2.3.1 Multilayer Perceptron

De acordo com Gualda (2008), as redes neurais artificiais são diferenciadas quando comparadas a outras técnicas, devido ao aprendizado que elas possuem. No qual, os valores são propagados pela rede através de pesos de conexão entre os neurônios, os pesos de conexão são ajustados através de um método de aprendizado, por exemplo o método de retropropagação.

As RNA's que possuem duas camadas, sendo uma camada de entrada e outra de saída possuem um desempenho muito limitado, o que torna necessário a adição de uma camada intermediária. Além disso, uma rede com três camadas é suficiente para representar qualquer função ou problema de classificação (GUALDA, 2008).

De acordo com Rodriguez (2019), a dificuldade das redes neurais em resolver problemas linearmente não separáveis, por exemplo, o XOR (ou exclusivo), é uma das principais limitações dos modelos *perceptrons*. Com isso, novas estratégias foram utilizadas para combater esse problema, como adicionar camadas intermediárias a partir da criação da rede *multilayer perceptron* – MLP.

As redes MLP possuem um poder computacional muito maior do que redes sem camadas intermediárias e permite a solução de problemas onde as classes são não-linearmente separáveis, adicionando camadas ocultas para o processamento e utilizando uma função de ativação não linear (GUALDA, 2008).

O ajuste dos pesos nas camadas ocultas é realizado através do aprendizado supervisionado, para um conjunto de amostra de entrada existe uma respectiva saída. Além disso, cada neurônio de uma camada oculta ou de saída é projetado para calcular a saída de um sinal por meio de uma função não linear e calcular o valor do gradiente para minimizar o erro a partir do algoritmo de retropropagação (*backpropagation*) (RODRIGUES, 2019), baseado numa regra de aprendizagem que ajusta o erro durante o treinamento (GUALDA, 2008).

A figura abaixo apresenta a arquitetura de uma rede *multilayer perceptron* com uma camada de entrada, duas camadas ocultas e uma camada de saída (HAYKIN, 2009). A partir desta configuração, cada neurônio está ligado com todos os outros das camadas vizinhas em uma comunicação unidirecional, contudo neurônios da mesma camada não se comunicam

(GUALDA, 2008). Os estímulos / sinais são apresentados a rede pela camada de entrada e são propagados para frente sem nenhuma alteração (*feedforward*) (RODRIGUES, 2019).




Figura 3: Arquitetura de uma rede multilayer perceptron com duas camadas intermediárias (HAYKIN, 2009)

Haykin (2009) descreve de acordo com observações da figura acima, os seguintes pontos: Os sinais de entrada (*input signal*) chegam a partir da camada de entrada (*input layer*) da rede e se propagam adiante, neurônio por neurônio. Na camada de saída (*output layer*) resultam os sinais de saída, que desempenham uma função útil na saída da rede e de acordo como atravessam a rede, o sinal é calculado como uma função das entradas e pesos associados aplicados a cada neurônio. Um sinal de erro se origina no neurônio de saída da rede e se propaga para trás (camada por camada) através da rede.

### 2.3.2 Redes Neurais Recorrentes

Redes neurais artificiais mais simples, como a *multilayer perceptron*, recebem os sinais a partir da camada de entrada e atravessam a rede até a camada de saída (*feedforward*). Entretanto, em uma rede neural recorrente a camada oculta pode receber tanto informações da camada de entrada quanto informação dela mesma na interação anterior (*feedback*), o que permite, por exemplo, trabalhar com modelagens temporais e espaciais (RODRIGUEZ, 2019).

Segundo Rodriguez (2019), este processo de *feedback* permite que o estado oculto passe a funcionar como uma memória de curto prazo através dos *feedbacks* existentes na rede. Com isso, o estado oculto pode fornecer informações para a camada de saída a fim de realizar uma previsão bem como fornecer informações para o estado oculto do próximo passo.

### 2.3.2.1 Long Short-Term Memory

Segundo Hochreiter e Schmidhuber (1997), redes neurais recorrentes por meio de suas conexões de *feedback* podem armazenar representações de eventos de entrada recentes em forma de ativações, chamadas de memória de curto prazo (*short-term memory*). O que permite a sua utilização em diversas aplicações, como o processamento de fala e composição musical (HOCHREITER; SCHMIDHUBER, 1997).

Um grande problema relacionado a redes neurais recorrentes são os algoritmos utilizados para aprender o que colocar na memória de curto prazo, no qual levam muito tempo ou não funcionam muito bem (HOCHREITER; SCHMIDHUBER, 1997).

Utilizando aprendizagem recorrente em tempo real, sinais de erro que retrocedem no tempo tendem a explodir ou desaparecer, a evolução temporal do erro retropropagado depende exponencialmente do tamanho dos pesos, o que pode levar, por exemplo, a pesos oscilantes ou a tempos que inválidos (HOCHREITER; SCHMIDHUBER, 1997).

A arquitetura recorrente chamada Memória de Longo Prazo (*Long Short-Term Memory* – LSTM), proposta por Hochreiter e Schmidhuber (1997), foi desenvolvida para superar esses problemas de retorno de erros. As LSTM's são projetados explicitamente para evitar o problema de dependência a longo prazo, lembrar informações por longos períodos de tempo é a principal característica dessa arquitetura (OLAH, 2015).

As LSTM's aprendem a diminuir os intervalos de tempo em excesso de 1000 etapas, mesmo no caso de sequências de entrada barulhentas e incompressíveis. Além disso, é um algoritmo eficiente e baseado em gradiente para uma arquitetura que aplica erros constantes, impedindo que explodam e desapareçam (HOCHREITER; SCHMIDHUBER, 1997).

### 3 TRABALHOS CORRELATOS

No decorrer deste trabalho realizou-se uma revisão bibliográfica da literatura com o objetivo de identificar o estado da arte de modelos e métodos utilizados para a detecção de *fake news*. Deste modo, foi possível identificar as principais características utilizadas nas detecções, tais como: Variáveis utilizadas nos modelos; Arquiteturas de Redes Neurais utilizadas; Métricas de erro para análise de qualidade da detecção.

A seguir são elucidados os trabalhos selecionados e comparados suas principais características que respondem as perguntas de pesquisa da revisão sistemática.

Segundo estudos realizados por Adbullah, Qawasmeh e Tawalbeh no ano de 2019, foi utilizado o conjunto de dados fornecido pelo *Fake News Challenge* (FNC), sendo um o conjunto correspondente a um total de 49.972 pares de títulos e textos (na língua inglesa), separados em 60% para treinamento, 20% para validação e 20% para teste. As entradas foram transformados em espaço vetorial usando o modelo vetorial de quatro palavras do Google News pré treinado com 300 dimensões, retirado de 3 bilhões de palavras em execução da Wikipédia, além disso também foi utilizado a biblioteca Gensim para o mapeamento das palavras em vetores de números reais como pesos iniciais. Foram utilizados dois modelo para a detecção das *fake news*, o primeiro modelo é o LSTM bidirecional concatenado (*Bidirectional LSTM concatenated*) com *accuracy* de 85% e precisão de 88%. O segundo modelo é o LSTM de várias cabeças (*Multi-head LSTM*) com *accuracy* de cerca de 83% e precisão de 84,5%. LSTM refere-se à *Long short-term memory* – Memória de longo prazo.

No artigo de Dawn, Mittal e Verma (2019) para preparo do conjunto de dados foram utilizados as bibliotecas NLTK (*Natural Language Toolkit*) e *FastText*. Além disso, também foi utilizado a tokenização de texto de pré-processamento do keras. O conjunto de dados (na língua inglesa) em sua grande parte possui apenas notícias indianas e foi buscado a partir dos sites: *Faking News*, *Rising Kashmir* e *Germany investigating unprecedented spread of fake news online*. Para a avaliação dos resultados foi utilizado a matriz de confusão. Utilizando um conjunto de dados de 20.000 artigos de notícias, o modelo LSTM mostrou uma precisão de 94,3% e perda de 0,209. O modelo GRU (Unidades Recorrentes Raladas – *Grated Recurrent Units*) gerou uma precisão de 91,9% e perda de 0,011. Após o primeiro teste, o modelo que apresentou o melhor resultado, neste caso o modelo LSTM, foi utilizado em um segundo teste com um conjunto de dados de 72.000 notícias, no qual obteve uma precisão de



99,04% e perda de 0,11165.

No artigo realizado pelo autor Maruno em 2018, para a construção do conjunto de dados foi buscado notícias verdadeiras a partir do site de notícias da Universidade Estadual de Londrina, a Agência UEL e o site do G1. Já as falsas notícias foram buscadas a partir de sites como o Diário de Pernambuco e o Sensacionalista. Para o pré-processamento do *dataset* foram utilizados as bibliotecas Gensim e NLTK, e a avaliação dos resultados é realizada a partir das métricas acurácia, precisão e revocação (*recall*). Com isso, o modelo LSTM obteve o melhor resultado geral, com acurácia média de 79.3% em textos pré processados, o modelo RF (*Random Forest*) obteve uma acurácia média de 78.2% e o modelo SVM (*Support Vector Machine*) obteve uma acurácia média de 67.2%.

## REFERÊNCIAS

ADBULLAH, Malak; QAWASMEH, Ethar; TAWALBEH, Mais. Automatic Identification of Fake News Using Deep Learning. **2019 Sixth International Conference on Social Networks Analysis, Management and Security (SNAMS)**. IEEE. 2019.

AOS FATOS. **Aos Fatos | Valorize o que é real**. Disponível em: <https://aosfatos.org/>. Acesso em: 08 abr. 2020.

BARBOSA, Maria Luciene Sampaio; SANTI, Vilso Junior. A intencionalidade nas notícias falsas: A nota de repúdio como estratégia de defesa do jornalismo na era das fake news. **Revista Pan-amazônica de Comunicação**, Palmas, v. 3, n. 3, p. 93-109, 2019.

BAUM, Matthew A. et al. The science of fake news. **American Association for the Advancement of Science**, 1200 New York Avenue NW, Washington, DC 20005. Vol. 359, mar. 2018.

BENGIO, Yoshua; GOODFELLOW, Ian; COURVILLE, Aaron. Deep Learning: Methods and Applications. 2015.

CHATURVEDI, Anumeha. **2019 – The year of fake news**. Disponível em: <<https://economictimes.indiatimes.com/news/politics-and-nation/fake-news-still-a-menace-despite-government-crackdown-fact-checkers/articleshow/72895472.cms>>.

DAWN, Suma; MITTAL, Vanshika; VERMA, Abhishek. FIND: Fake Information and News Detections using Deep Learning. IEEE. 2019.

DENG, Li; YU, Dong. Deep Learning: Methods and Applications. **Foundations and Trends® in Signal Processing**. Vol. 7. 2013.

DELMAZO, Caroline; VALENTE, Jonas C. L.. Fake news on online social media: propagation and reactions to misinformation in search of clicks: Propagation and reactions to misinformation in search of clicks. **Media & Jornalismo**, v. 18, n. 32, p. 155-169, 2018. Coimbra University Press.

FAKE NEWS. In: DICIONÁRIO Cambridge Advanced Learner's Dictionary & Thesaurus. Cambridge University Press, 2020.

FURTADO, Maria Inês Vasconcellos. **Redes Neurais Artificiais: Uma Abordagem Para Sala de Aula.** **Ponta Grossa: Atena Editora,** 2019.

FINOCCHIO, Marco Antonio Ferreira. **Noções de Redes Neurais Artificiais.** 2014. Universidade Tecnológica Federal do Paraná.

GUALDA, Isabella Peres. **Aplicação de Redes Neurais Artificiais na Ciência e Tecnologia de Alimentos: Estudo de Casos.** 2008. 152 f. Dissertação (Mestrado) - Curso de Ciência de Alimentos, Universidade Estadual de Londrina, Londrina, 2008.

HAYKIN, Simon S. **Neural networks and learning machines.** Third. Upper Saddle River, **NJ: Pearson Education,** 2009.

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. Long short-term memory. **Neural computation,** MIT Press, v. 9, n. 8, p. 1735–1780, 1997.

IFCN. **IFCN Code of Principles.** Disponível em: <https://ifcncodeofprinciples.poynter.org/signatories>. Acesso em: 08 abr. 2020.

LIM, Zheng W.; LING, Richard; TANDOC JR, Edson C. Defining “Fake News”. **Digital Journalism.** Aug 2017.

MARUNO, Fabiano. **Deep learning para classificação de fake news por sumarização de texto.** Londrina. 2018.

OLAH, Christopher. **Understanding LSTM Networks.** 2015. Disponível em: <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>. Acesso em: 13 abr. 2020.

RIBEIRO, Márcio Moretto; ORTELLADO, Pablo. O que são e como lidar com as notícias falsas. **Revista Internacional de Direitos Humanos, Sc,** v. 5, p. 71-83, 2018.

SPINELLI, Egle Müller; SANTOS, Jéssica de Almeida. JORNALISMO NA ERA DA PÓS-VERDADE: fact-checking como ferramenta de combate às fake news. : fact-checking como ferramenta de combate às fake news. **Revista Observatório,** [s.l.], v. 4, n. 3, p. 759-782, 29 abr. 2018. Universidade Federal do Tocantins.

RODRIGUES, Welington Galvão. **Predição de Diâmetros e Cálculo de Volume de Clones de Eucalipto:** uma abordagem com redes multilayer perceptron e long-short term memory. 2019. 95 f. Dissertação (Mestrado) - Curso de Ciência da Computação, Universidade Federal

de Goiás, Goiânia, 2019.

TIN, Pham T. A Study on Deep Learning for Fake News Detection. **Japan Advanced Institute of Science and Technology**. Mar, 2018.

TRAUMANN, Thomas. Como a indústria de notícias falsas dominou a eleição da França. **Época**. 20 abr. 2017.